

TÀI LIỆU KIỂM DUYỆT KỸ THUẬT

BÁO CÁO KIỂM DUYỆT VECTOR SEARCH & LỘ TRÌNH CẢI TIẾN HỆ THỐNG HUIT CHATBOT

Phân tích chuyên sâu khâu Vector Search, so sánh độ phức tạp với chuẩn SOTA 2025–2026 và kế hoạch nâng cấp mô hình.

Dự án: HUIT AI Chatbot

Đối tượng kiểm duyệt: Subsystem Vector Search & RAG Core

Cơ sở dữ liệu: MongoDB Atlas (huit_chatbot)

Embedding Model: FastEmbed MiniLM-L12-v2 (384D)

Phiên bản: v3.1 (Audit Report)

Ngày lập: 24/07/2026

1. Tổng Quan Kiểm Duyệt Hệ Thống HUIT Chatbot

Dự án được xây dựng theo kiến trúc **Modular RAG** kết hợp triết lý **"1 JSON = 1 Module Code"** và giao thức **MCP (Model Context Protocol)**. Hệ thống quản lý tri thức của 39 ngành đào tạo chính quy HUIT cùng các dữ liệu học phí, điểm sàn, học bổng từ cổng tuyển sinh `ts.huit.edu.vn`.

- RAG Orchestrator:** `api.py` (FastAPI) & `rag_core.py`.
- MCP Server:** `mcp_server.py` triển khai chuẩn Stdio cung cấp công cụ `ask_huit_admission` và `search_huit_kb`.
- Kiến trúc Module JSON:** `huit_semantic_search.module.json` và `huit_rag_answer.module.json` đóng gói đường ống truy vấn MongoDB.
- Multi-LLM Fallback:** Qwen 2.5 72B → Llama 3.3 70B → Gemini 2.0 Flash → GPT-3.5 Turbo.

2. Kiểm Duyệt Chi Tiết Khâu Vector Search (Vector Search Subsystem)

Khâu Vector Search chịu trách nhiệm nhúng (embed) câu hỏi người dùng và tìm kiếm đoạn văn bản tương đồng ngữ nghĩa nhất trong MongoDB Collection `huit_kb`.

2.1 Thông số cấu hình hiện tại:

- Embedding Model:** `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` chạy offline qua thư viện `fastembed` (ONNX).
- Vector Dimension:** 384 chiều.
- Distance Metric:** Cosine Similarity.
- Vector Store:** MongoDB Atlas Vector Search index `huit_vector_index`.
- Retrieval Strategy:** Dense Vector Search (`numCandidates=100`, `limit=top_k`) + Regex Keyword Fallback + Heuristic Document Injection.

2.2 Nhược điểm & Điểm nghẽn kỹ thuật trong khâu Vector Search:

- Hạn chế Không gian Vector (384D)** : Mô hình 384 chiều có dung lượng nhẹ nhưng khoảng không gian biểu diễn ngữ nghĩa bị hạn chế đối với câu hỏi tiếng Việt phức tạp, nhiều từ ghép hoặc từ viết tắt.
- Chiến lược Cắt đoạn (Chunking) cố định** : Đang dùng cắt đoạn theo ký tự (`max_chunk_size = 750`). Chưa có *Contextual Chunking* nên một số chunk bị mất ngữ cảnh ngành học gốc.
- Thiếu Khâu Re-ranking** : Chưa có mô hình Cross-Encoder Re-ranker để đánh giá lại điểm số relevance giữa câu hỏi và Top-K chunks.
- Thiếu Hybrid Search chuẩn hóa** : Tìm kiếm vector và regex đang chạy nối tiếp chứ chưa được kết hợp điểm số bằng thuật toán **Reciprocal Rank Fusion (RRF)**.

3. Đánh Giá Độ Cải Tiến & So Sánh Với Chuẩn SOTA (2025–2026)

Hệ thống hiện đạt mức **Intermediate Modular RAG (RAG Trung Cấp)** với độ phức tạp đạt **6.5 / 10**. Dưới đây là bảng đối sánh với tiêu chuẩn công nghệ RAG doanh nghiệp hiện tại:

Tiêu chí kỹ thuật	Hệ thống HUIT hiện tại	Chuẩn SOTA 2025–2026	Đánh giá nâng cấp
Embedding Model	FastEmbed MiniLM-L12 (384D)	BAAI/bge-m3 (1024D) / multilingual-e5-large	Nâng cấp 1024D (+30% recall)
Retrieval Pipeline	Dense Search + Fallback Regex	Hybrid Search (Dense + Sparse BM25) + RRF	Bắt chính xác mã ngành/số liệu
Chunking Strategy	Cắt ký tự cố định (~750 chars)	Contextual Retrieval (Gắn Metadata & Title)	Loại bỏ chunk mất ngữ cảnh
Re-ranking Stage	Không có	Cross-Encoder Reranker (bge-reranker-v2-m3)	Rất quan trọng (Giảm hallucination)
Evaluation Framework	Script test thủ công	Khung đánh giá tự động RAGAS / TruLens	Đo lường định lượng cụ thể

4. Lộ Trình Cải Tiến Mô Hình (Model Upgrade Roadmap)

Mục tiêu cải tiến: Đưa độ chính xác truy vấn (Context Recall) lên >92%, giảm thiểu ảo giác của LLM xuống <2%, tối ưu thời gian phản hồi <1.2s.

Giai đoạn 1: Contextual Chunking & Upgrade Embedding 1024D

- Chuyển mô hình Embedding sang `BAAI/bge-m3` hoặc `intfloat/multilingual-e5-base` (tăng từ 384D lên 1024D).
- Cập nhật pipeline trong `build_real_kb.py` : Tự động chèn metadata [Ngành: | Mã:] vào đầu từng văn bản chunk trước khi tạo embedding.
- Khởi tạo lại Atlas Vector Search Index với `numDimensions: 1024` .

Giai đoạn 2: Tích hợp Re-ranker & Hybrid Search

- Thêm mô hình Re-ranker nhẹ (`bge-reranker-v2-m3` hoặc `ms-marco-MiniLM-L-6-v2`). Truy vấn 15 candidates từ MongoDB, sau đó re-rank lấy Top 3 cho LLM.
- Kết hợp thuật toán Reciprocal Rank Fusion (RRF) cho Dense Vector Search và Sparse Keyword Search.

Giai đoạn 3: Đánh giá tự động với RAGAS Framework

- Tạo dataset 50 câu hỏi benchmark kèm đáp án chuẩn (Ground Truth).
- Chạy RAGAS evaluator đo chỉ số Faithfulness, Answer Relevance, Context Recall và Context Precision.

XÁC NHẬN CHUYỂN GIAO: File PDF này đóng vai trò bản báo cáo kiểm duyệt chính thức. Ngay sau đây, chúng ta sẽ bắt đầu bắt tay vào việc thực thi Giai đoạn 1 của Lộ trình Cải tiến.